Agendamiento estructurado de reuniones desde lenguaje natural

Generative Artificial Intelligence (580694) – Universidad de Concepción – Spring 2026
Matias Arriagada — Cristián Cárdenas — Pablo Silva — Daniela Vidal

1. Tarea y criterio de *éxito*

Convertir mensajes naturales (español/inglés, incluidos mensajes informales) en un evento JSON listo para una API de calendario. El contrato exige ocho campos: `titulo`, `fecha` (YYYY-MM-DD), `hora_inicio` (HH:MM), `duracion_minutos`, `participantes`, `ubicacion`, `recordatorio_minutos` y `zona_horaria`. **Correcto** significa: todos los valores coinciden con el ground truth; se conservan los datos mencionados, se usa `null`/`[]` cuando falta información y no se inventan valores. Las fechas relativas se calculan desde el 1-09-2026 (martes). Benchmark2 contiene 45 frases en seis categorías: simple, con participantes, ambigua, compleja, edge case y chat.

2. Diagnóstico basado en evidencia

Evaluamos cuatro modelos en Benchmark2 (45 frases, mismo conjunto), más un baseline adicional en Benchmark1 (35 frases):

Modelo	Exactitud	Configuración
TinyLlama-1.1B	6/45 (13.3%)	Prompt directo
Qwen2-0.5B	0/35 (0.0%)	Prompt directo (Benchmark1)
Qwen4B-Instruct	20/45 (44.4%)	Prompt directo
Mistral-7B-Instruct	27/45 (60.0%)	Prompt directo
Qwen3-4B-Instruct-2507	**29/45 (64.4%)**	System prompt + few-shot + post-proc.

El patrón es claro: los modelos pequeños (1–2B) fallan en formato y referencia temporal; los medianos (4–7B) mejoran sustancialmente; la combinación de instrucciones estructuradas y post-procesamiento determinista supera el prompting directo.

Métricas por campo (Benchmark2):

Campo	TinyLlama	Mistral7B	Campo	TinyLlama	Mistral7B
`titulo`	42.2%	84.4%	`fecha`	53.3%	93.3%
`hora_inicio`	57.8%	95.6%	`duracion`	62.2%	97.8%
`participantes`	55.6%	82.2%	`ubicacion`	62.2%	91.1%
`recordatorio`	73.3%	97.8%	`zona_horaria`	73.3%	100.0%

Qwen4B obtuvo 44.4% con prompting directo; Mistral-7B logra 60.0% (misma configuración); Qwen3 con pipeline mejorado alcanza 64.4%. Los errores dominantes en TinyLlama son `ERROR_MODELO` (salida inválida) y fechas relativas incorrectas; Mistral falla principalmente en participantes (82.2%) y título (84.4%).

Qwen3 pipeline mejorado por campo: titulo 82.2%, fecha 82.2%, hora_inicio 100.0%, duracion 100.0%, participantes 93.3%, ubicacion 100.0%, recordatorio 100.0%, zona_horaria 100.0%. Por categoría: simple 87.5%, con participantes 71.4%, ambigua 42.9%, compleja 71.4%, edge case 75.0%, chat 37.5%.

3. Modelos candidatos open-weight (≤8B)

Modelo	Params	VRAM	Razón para esta tarea
TinyLlama-1.1B	1.1B	∼2GB	Baseline de bajo costo: 13.3% en Benchmark2; viable en CPU.
Qwen4B-Instruct	4B	∼8GB	Referencia intermedia: 44.4% sin post-procesamiento.
Mistral-7B-Instruct	7B	∼5GB (4-bit)	Mayor capacidad sin fine-tuning: 60.0%; buen razonamiento temporal.
Qwen3-4B-Instruct-2507	4B	∼8–10GB	Mejor resultado: 64.4% con instrucciones, few-shot y normalización.

4. Factibilidad de ejecución

Entorno comprobado: Google Colab gratuito con GPU NVIDIA T4 (16GB). **Stack:** PyTorch, Transformers, bitsandbytes. TinyLlama y Qwen4B caben en CPU; Mistral cuantizado (4-bit) y Qwen3 en FP16 caben en T4. `evaluar.py` calcula exactitud global, por campo/categoría y tipos de error; el notebook valida JSON, esquema y benchmark antes de ejecutar.

5. Repositorio y estado

github.com/maty20arriagada/SML-GEN-AI-for-Calendar-services

Incluye equipo, especificación de tarea, Benchmark2 con ground truth, `evaluar.py`, notebooks (baseline y Qwen3 mejorado), reportes CSV de los cuatro modelos, resultados normalizados y guía de ejecución.