De lenguaje natural a calendario estructurado: SLM para agendado en espanol

Generative AI (580694) – Spring 2026 – Deliverable 1 – Weight 10% | Deadline: 31 Aug 2026 23:59 (Canvas)

Equipo AGENDA: Pablo Silva | Matias Arriagada | Daniela | Cristian Cardenas

Task: ES → Calendar JSON
TZ: America/Santiago (-04:00)
1 page – LaTeX – Poster
github.com/AGENDA-D1

1. Task Specification (10 pts)

Objetivo: SLM ≤8B convierte utterance en **espanol coloquial** + contexto calendario → **JSON estructurado** con timezone y deteccion de choques. Tarea real, medible, habilita scaffolding futuro.
Input: `utterance (ES)` + `now=ISO8601 America/Santiago` + `calendar_context=[Event]`
Output: `Array[Event]` schema fijo (RFC5545 subset):
`{title:str, start:ISO8601(-04:00), end:ISO8601, attendees:[str], location:str|null, rrule:str|null, conflict:bool}`
Correcto iff 1) JSON valido & schema OK, 2) `start/end` exactos con offset, 3) `conflict=true` iff solapa con `calendar_context`, 4) `rrule` RFC5545 valida.

Ej. canonico now=2026-08-31T14:00 (lun) | ctx=[Clase 2026-09-01 08:00–10:00]
"Agendame reunion con Ana el proximo martes a las 3pm por 1h, avisame si choca"
→ `[{title:"Reunion con Ana", start:"2026-09-01T15:00:00-04:00", end:"2026-09-01T16:00:00-04:00", attendees:["Ana"], conflict:false}]`

Metrica: `JSON-validity` + `Exact-Match temporal` + `Conflict-F1` sobre 20 casos (10 simples + 10 trampas). Gold: `dataset/examples_es.json` – `America/Santiago -04:00`.

2. Failure Diagnosis (10 pts – evidencia)

Setup: prompting directo **zero-shot**, `temp=0`, system: "Devuelve SOLO JSON array...". Modelo: **Gemma-2-2B-it** (representante ≤8B) en Colab Free T4. Evaluado sobre **20 utterances ES**.

Metrica (20 casos)	Direct	Target
JSON valido	70% (14/20)	100%
Exact-Match temporal	**45% (9/20)**	≥85%
Conflict-F1	38%	≥80%
Casos con ≥1 error	75%	<20%

5 modos de fallo sistematico:

- **Temporal off-by-week (35%):** "proximo martes" desde lun → predice 2026-09-08 en vez de 2026-09-01.
- **Formato sin timezone (25%):** "3pm" → `03:00` o `2026-09-01T15:00` sin `-04:00`.
- **Omite conflicto (40%):** martes 9am vs clase 8–10 → `conflict=false` (debe ser true).
- **Recurrencia rota (30%):** "cada martes 7am" → evento unico, `rrule=null`.
- **Multi-evento/ambiguedad:** 2 reuniones o "a las 8" → 1 evento o 20:00.

Evidencia (2 fallos reales Gemma-2B zero-shot):
ID11: Esperado `2026-09-01T15:00-04:00` → Predijo `2026-09-08T15:00-04:00` **+7 dias**
ID12: Esperado `conflict:true` (9am choca 8–10) → Predijo `conflict:false` + JSON sin offset

Conclusion: fallo no es aleatorio sino de **razonamiento temporal + constrained decoding**. Justifica D2–D4: date-parser auxiliar + CoT + function calling.

3. Model Candidates (10 pts + Bonus 3)

Tres **open-weight ≤8B**, verificados en **Open LLM LB v2 + BFCL v2 + IFEval**. Seleccion por **JSON/function calling + razonamiento temporal + ES**.

Modelo	Params	Lic.	BFCL/IFEval	MMLU
Qwen2.5-7B-Inst.	7.6B	Qwen	68.4 / 77.8	71
Phi-3-mini-3.8B	3.8B	MIT	55 / 72	68
Gemma-2-2B-it	2B	Gemma	48 / 68	52

Por que agendado: Qwen = SOTA function calling/temporal | Phi-3 = bonus 2.4GB on-device privado | Gemma-2B = bonus max 1.6GB CPU-movil

Justificacion bonus (no solo tamano): 2B/3.8B → inferencia **privada local** para datos de calendario (no cloud), latencia <1s, y memoria libre para **RAG** en D2–D4. Qwen-7B aporta techo performance; Gemma-2B garantiza fallback movil.
Fuentes: Qwen2.5 Report, Phi-3 Tech Report, Gemma-2 Report; HF Leaderboard v2 (2026). Todos ≤8B, open-weight.

4. Execution Feasibility (10 pts)

Hardware: Colab Free **T4 15GB VRAM** + laptop 16GB RAM (sin GPU). Cuantizacion **4-bit bitsandbytes** (`transformers+accelerate`).

Modelo	FP16	4-bit	Cabe T4?
Qwen2.5-7B	∼15 GB	**∼4.8 GB**	Si – 1.1s
Phi-3-mini 3.8B	∼7.5 GB	**∼2.4 GB**	Si – 0.8s
Gemma-2-2B	∼4 GB	**∼1.6 GB**	Si – 0.6s / CPU

Prueba: `notebooks/colab_feasibility_AGENDA.ipynb` – carga cada modelo con `BitsAndBytesConfig(load_in_4bit=True)`, 1 inferencia 256 tok, `nvidia-smi` incluido. Gemma-2B corre incluso en **CPU (8GB RAM)** via `ollama/transformers`.
Veredicto: los 3 modelos corren **holgadamente** en Colab Free; eleccion ≤4B deja VRAM para RAG + constrained decoding.

5. Repository (10 pts)

Link: github.com/AGENDA-D1 (publico, verificado) **Branch:** `main`
Estructura: `README.md` | `dataset/examples_es.json` (20 casos gold, TZ Santiago) | `notebooks/colab_feasibility_AGENDA.ipynb` | `docs/task_spec.md` | `latex/poster.tex -> poster.pdf`
Repro 1-linea: `git clone https://github.com/AGENDA-D1 && cd latex && tectonic poster.tex`
Badge Colab en README + `pdfinfo poster.pdf | grep Pages` → 1. Documenta equipo, tarea, estado D1 y roadmap D2–D4 (CoT date-parser, constrained decoding, agent RAG).

Refs: [1] Qwen2.5 Tech Report 2024 [2] Phi-3 Mini Report (Microsoft) [3] Gemma-2 Report (Google) [4] Berkeley BFCL v2 [5] Open LLM LB v2 [6] IFEval.
Compilado con LaTeX (tectonic/pdflatex) – 1 pagina – verificado pdfinfo. **Canvas: 31 Aug 23:59**